


2026ProteinDesign — GFP 荧光亮度预测与进化优化

基于 ESM 蛋白语言模型嵌入 + 残差网络回归预测 GFP 荧光亮度及热稳定性 (T_m)，结合 ESM3 掩码语言模型 + S4PRED 二级结构引导进行多目标进化优化，设计高亮度、高热稳定性的 GFP 蛋白变体。合成生物学竞赛项目。

整体算法管线

本项目由两个阶段构成：**第一阶段**训练亮度预测回归器，**第二阶段**利用该回归器结合 T_m 预测器进行多目标进化优化。



外部模型依赖（需从 GitHub 克隆到项目同级目录）：

- [ProCeSa](#) — 热稳定性预测 GNN，放置在 `../ProCeSa/`（即与本项目同级的 ProCeSa 目录）
- [s4pred](#) — 二级结构预测，放置在 `../s4pred/`

数据准备

将原始 `GFP_data.xlsx` 转换为训练数据集（含 ESM 嵌入）：

```
python utils/export_dataset_json.py
```

处理流程：

1. **突变解析** — `convert_gfp_data.py` 解析突变字符串（如 `S65G:Y66F` 将丝氨酸65突变为甘氨酸、酪氨酸66突变为苯丙氨酸），在对应野生型序列上应用所有突变得完整序列；支持多突变（`:` 分隔）和插入（`*OM`）。

2. 序列过滤 — 仅保留长度在 225~250 aa 之间的序列。
3. 嵌入提取 — 使用 ESMC-6B 模型（Biohub/ESMC-6B，600M 参数）提取每条序列的 per-residue 嵌入，输出 `[250, 2560]`（不足250补零，超出截断）。
4. 5段平均池化 — 将 `[250, 2560]` reshape 为 `[5, 50, 2560]`，沿残基轴（axis=1）取均值，得到 `[12800]` 单一向量。大幅降低存储占用（~341 GB → ~5.5 GB）。
5. 分片导出 — 每 1000 条记录为一个分片，分别写入 JSON（序列与标注）和 .npy（池化嵌入）。

输出文件：

- `gfp_dataset_shard_{NNN}.json` — 分片序列、GFP类型、亮度标注
- `gfp_dataset_shard_{NNN}_embeddings.npy` — 分片池化嵌入 `[N, 12800]`
- `gfp_dataset_shards.json` — 分片清单（总记录数、分片数、各分片路径与记录数）

训练配置

参数	值	说明
<code>embed_dim</code>	12800	输入维度（5段 × 2560）
<code>learning_rate</code>	5e-4	Adam 学习率
<code>num_epochs</code>	500	最大训练轮数
<code>checkpoint_freq</code>	30	每 N 轮保存检查点
<code>early_stopping_patience</code>	40	验证损失不再下降则提前终止
<code>batch_size</code>	512	训练/验证/测试批次大小
<code>seed</code>	114514	全局随机种子（数据划分、参数初始化）

训练细节：

- 损失函数：MSE，目标值为 `log1p(brightness)`（将亮度对数压缩至约 1.3~3.8 范围）
- 优化器：Adam (lr=5e-4)，配合 ReduceLROnPlateau（因子0.5，patience=15）
- 梯度裁剪：`max_norm=1.0`，每批次应用
- 数据加载：GPU 上 4 workers + pin_memory，CPU 上 0 workers
- 每轮评估验证集 R²（将 `expm1` 恢复后的预测亮度与真实亮度比较）

输出文件：

- `model_final.pth` — 最终模型权重 + 优化器状态 + 配置
- `checkpoints/best_model.pth.tar` — 验证损失最低的检查点
- `checkpoints/checkpoint_epoch_{N}.pth.tar` — 周期检查点
- `training_logs.json` — 每轮训练/验证损失、学习率历史
- `evaluation_results.json` — 测试集 MSE、R²、100 条随机样本预测详情

配置参数

参数	默认值	说明
<code>batch_size_per_parent</code>	200	每轮每个父代生成的子序列数

参数	默认值	说明
top_k_ratio	0.1	每轮保留比例（Top 10%）
max_parents	20	每轮最大父代数
drop_rate	0.05	序列中随机掩码的残基比例（5%）
temperature	1.5	ESM3 生成温度（实际加 ±20% 随机扰动，范围 1.2~1.8）
num_rounds	10	进化迭代轮数
num_steps	8	ESM3 生成步数
seed	42	进化管线随机种子
min_sequence_length	225	最小有效序列长度
max_sequence_length	250	最大有效序列长度
model_path	model_final.pth	亮度预测模型路径
tm_config	configs/S_esmc/model3.py	ProCeSa 模型配置（相对 ProCeSa/procesa/）
tm_checkpoint	results/S_esmc/seed-101/model3/epoch_best.pth	ProCeSa 模型权重

序列生成

1. 二级结构预测

— 对每条父序列运行 S4PRED，获得每个残基的二级结构（H=螺旋, E=折叠, C=无规卷曲）。
2. 掩码策略

— 在下述位置以外随机选择 5% 残基替换为 _（掩码token）：
 - 锁定位置：sfGFP 的 21 个关键功能残基（M1, R30, N39, L64, T65, Y66, G67, Q94, R96, S99, T105, F145, P147, H148, T153, A163, V171, T203, S205, V206, E222），保护发色团形成、荧光活性和折叠稳定性相关位点。
 - 非coil区域：S4PRED 预测为 H 或 E 的残基不参与掩码，仅对无规卷曲（C）区域的残基进行掩码，避免破坏蛋白核心结构。
3. ESM3 生成

— 使用 esm3-open 模型对被掩码的序列进行 8 步迭代生成，温度为 1.5 ± 20%（每批次随机扰动，增加多样性）。
4. 质量控制

— 去重 → 排除含无效氨基酸（BJOUXZ）的序列 → 排除 Exclusion_List.csv 中的 13w+ 条已知序列 → 长度检查（225~250 aa）。

双维评估与综合评分

对每轮生成的所有有效序列同时进行两项预测：

评估维度	工具	模型	输出
荧光亮度	EVAL (model/eval.py)	BrightnessRegressor (ResBlock MLP)	原始亮度值
热稳定性	TM_PREDICTOR (esm_utils/tm_predictor.py)	ProCeSa GNN	熔解温度 Tm (°C)

综合评分公式（轮内全局 Min-Max 归一化）：

```
b_norm = (brightness - b_min) / (b_max - b_min)      ∈ [0, 1]
dtm_norm = (ΔTm - ΔTm_min) / (ΔTm_max - ΔTm_min)    ∈ [0, 1]  (ΔTm = Tm - Tm_wt)
composite_score = b_norm² × dtm_norm
```

- 亮度权重为平方，优先优化荧光亮度，热稳定性作为辅助目标。
- 当轮内所有值相同时（零方差），归一化值退化为 0.5。

选择与迭代

- 按 composite_score 降序排列，保留 Top 10%（最多 20 条）作为下一轮父代。
- 迭代 10 轮后输出全局最佳序列及其评分。

输出

- pipeline_results_sfGFP.json — 完整结果（含配置、所有轮次、全局 Top-10、最佳序列）
- pipeline_results_sfGFP_round{N}.json — 每轮快照（父代、生成序列、Top 选择）
- 终端实时打印每轮 Top 序列的排名、综合评分、亮度、ΔTm、序列摘要

项目结构

```
.
├── main.py                # 进化优化主管线（亮度+Tm 多目标）
├── run.sh                 # 一键运行脚本
├── requirements.txt       # Python 依赖
├── GFP_data.xlsx         # 原始突变体数据（14w+）
├── AAseqs of 5 GFP proteins_20260511.txt # 野生型序列参考文件
├── Exclusion_List.csv     # 排除序列列表（13w+ 条）
├── submission_template.csv # 竞赛提交模板
├── model/
│   ├── BrightnessRegressor.py # ResBlock 回归模型定义
│   └── train.py              # 训练脚本（含 GFP_Dataset、训练循环、
评估)
│   ├── eval.py              # 亮度推理封装类（EVAL）
├── esm_utils/
│   └── esmc_embedding.py    # ESMC-6B 序列嵌入（per-residue
[250,2560])
```

```

├── esm3_generate.py          # ESM3-open 掩码序列生成（8步迭代）
├── tm_predictor.py          # ProCeSa Tm 预测封装类
(TM_PREDICTOR)
├── s4pred_wrapper.py        # S4PRED 二级结构预测封装
├── esmfold2_generate.py      # ESMFold2 结构预测（独立工具）
├── wt_extract.py            # 野生型嵌入提取
├── utils/
│   ├── export_dataset_json.py  # Excel → 分片 JSON + 池化嵌入
│   ├── convert_gfp_data.py    # 突变字符串解析与全长序列构建
│   ├── fpbase_crawler.py      # FPbase 荧光蛋白数据库爬取
│   ├── fpbase_to_fasta.py     # FPbase JSON → FASTA 转换
│   ├── analyze_ss2.py         # PSIPRED .ss2 二级结构文件解析
│   └── fetch_fireprotdb.py    # FireProtDB Tm 数据抓取
└── checkpoints/             # 训练检查点

```

技术细节

模型架构：BrightnessRegressor

Input: [batch, 12800] (5段平均池化后的 ESM 嵌入)

```

→ Linear(12800→4096) + BN + GELU + Dropout(0.3)
→ ResidualBlock(4096→4096, dropout=0.2)
→ ResidualBlock(4096→512, dropout=0.2)
→ ResidualBlock(512→256, dropout=0.1)
→ ResidualBlock(256→128, dropout=0.1)
→ ResidualBlock(128→64)
→ Linear(64→1) → squeeze

```

Output: [batch] (预测 log1p 空间亮度)

ResidualBlock = Linear → BatchNorm1d → GELU → Dropout → + shortcut(Identity 或 Linear投影)

嵌入处理：5段平均池化

```

ESMC-6B 输出:      [L, 2560]      (L = 序列长度, 补零/截断到250)
                    |
                    ▼
                [250, 2560]      (pad/truncate to 250)
                    |
                    ▼ reshape
                [5, 50, 2560]     (5段 × 每段50残基 × 2560维)
                    |
                    ▼ mean(axis=1)
                [5, 2560]         (每段取均值)
                    |
                    ▼ flatten
                [12800]           (最终特征向量)

```

相比直接使用 [250, 2560] 完整嵌入 (~640K 维)，池化后的 12800 维向量在保留结构信息的同时大幅降低了存储和计算开销。

数据说明

- 训练数据来自 5 种野生型 GFP (sfGFP, avGFP, amacGFP, cgreGFP, ppluGFP) 及其单点/多点突变体，共 14w+ 条
- 亮度值经 `log1p` 变换后作为回归目标：`label = ln(brightness + 1)`，取值约 1.3~3.8
- 序列长度过滤：225~250 aa (超出范围直接丢弃)
- 分片存储策略：每 1000 条一个分片，JSON+Numpy 配对，运行时按需 mmap 加载，降低内存占用

进化优化设计理念

策略	目的
锁定关键功能残基	保护发色团形成 (Y66, G67)、荧光活性 (T65, H148, E222) 和折叠稳定性 (L64, R96, F145)
S4PRED 二级结构引导掩码	仅对无规卷曲 (coil) 区域引入变异，保护 α -螺旋和 β -折叠等核心结构元件
温度随机扰动 ($\pm 20\%$)	增加每批序列多样性，平衡探索与利用
排除列表过滤	避免生成已知/已发表序列，保证设计新颖性
亮度 ² × ΔT_m 评分	亮度为主要优化目标 (平方加权)， T_m 为辅助约束，防止过度牺牲热稳定性
轮内全局归一化	每轮独立评分，奖励该轮中相对优势的序列，避免跨轮比较的尺度不一致